

Laporan Hasil Crawling Data

1. Data Awal

Data diperoleh melalui proses *scraping* postingan Instagram yang berkaitan dengan objek wisata di Lampung Selatan. Hasil scraping awal menghasilkan **7.178** gambar/postingan beserta metadata Instagram. Metadata tersimpan dalam CSV dengan 24 kolom, diantaranya:


<i>caption</i>	<i>location/id</i>
<i>owner/fullName</i>	<i>location/lat</i>
<i>owner/id</i>	<i>location/long</i>
<i>owner/isPrivate</i>	<i>location/name</i>
<i>owner/isVerified</i>	<i>location/slug</i>
<i>owner/profilePicUrl</i>	<i>createdAt</i>
<i>owner/username</i>	<i>id</i>
<i>url</i>	<i>image/height</i>
<i>likeCount</i>	<i>image/url</i>
<i>location</i>	<i>image/width</i>
<i>location/address</i>	<i>FileName</i>
<i>location/city</i>	<i>Downloadstatus</i>

2. Permasalahan Dataset

Setelah diperiksa, dataset awal masih mengandung banyak data yang tidak relevan atau *noise*. Contohnya:

- poster promosi wisata, *open trip*, dan jasa
- gambar ayat Al-Qur'an atau konten teks
- gambar duplikat
- thumbnail berita
- promosi usaha atau produk
- organigram organisasi
- foto selfie yang tidak menampilkan objek wisata
- serta konten lain yang tidak relevan dengan objek wisata Lampung Selatan

Berikut contoh noise yang ditemukan di dalam dataset



3. Proses Data Cleaning

Pembersihan dilakukan dengan pemeriksaan visual terhadap gambar. Gambar yang dianggap *noise* dihapus dari folder dataset, sedangkan gambar yang masih relevan dipertahankan. Setelah proses pembersihan gambar selesai, dilakukan sinkronisasi kembali dengan metadata. Nama file gambar yang masih tersisa dicocokkan dengan kolom `FileName` pada CSV. Baris metadata hanya dipertahankan apabila `FileName` tersebut masih memiliki file gambar yang sesuai.

4. Hasil Data Cleaning

Keterangan	Jumlah
Data awal	7.178
Data yang dihapus	4.489
Data setelah cleaning	2.689
Data dipertahankan	37,46%
Data dieliminasi	62,54%

Dari 7.178 data awal, sebanyak 4.489 data dieliminasi karena dianggap tidak relevan atau *noise*. Dataset akhir menghasilkan **2.689** data yang lebih sesuai dengan kebutuhan penelitian.

Link Data Cleaning : [Click here](#)